```
import seaborn as sns
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
#Download Dataset
data = pd.read_csv("https://cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud/IBM-ML241EN-
SkillsNetwork/labs/datasets/Human_Activity_Recognition_Using_Smartphones_Data.csv")
<code>data.dtypes.value_counts()</code>   #It will show you the count value of the types of data (ex. object, int, float etc.)
s = 0
for i in data.columns:
   if data[i].dtype == '0' :
       s+=1
       print(i)
print(s)
data.iloc[:,:-1].min().value_counts()
data.iloc[:,:-1].max().value_counts()
data['Activity'].value_counts()
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
data['Activity2'] = le.fit_transform(data.Activity)
data[['Activity','Activity2']].value_counts(sort=False)
#Create a new dataset with encoded column and drop the existing column which the type is object
data2 = data.drop(columns=['Activity'], inplace=False)
```

```
#Calculate the correlation between the dependent variable
#Correlation หรือ ค่าสหสัมพันธ์ เป็นการดูทิศทางความสัมพันธ์ระหว่างตัวแปร 2 ตัว
#โดยมี Correlation Coefficient (r) หรือ ค่าสัมประสิทธิ์สหสัมพันธ์ เป็นตัวบ่งชี้ถึงความสัมพันธ์นี้
#ซึ่งค่าสัมประสิทธิ์สหสัมพันธ์นี้จะมีค่าอยู่ระหว่าง -1.0 ถึง +1.0 ซึ่งหากมีค่าใกล้ -1.0 นั้นหมายความว่าตัวแปรทั้งสองตัวมีความสัมพันธ์ถันอย่างมากในเชิงตรงกันข้าม
#Feature columns except encoded column
feature_cols = data2.columns[:-1]
#Calculate corr values
corr_values = data2[feature_cols].corr() #return correlation matrix
tril_index = np.tril_indices_from(corr_values)
Coord = zip(*tril index) #return tuples of coordinate (ex. (0,0), (1,0), (1,1) etc.)
#Change the existing lower triagonal value to NaN due to this existing value is unused( ค่าที่ซ้ำกัน และ ค่าที่เกิดจาการเปลี่ยนเทียบของตัวเอง)
for x in Coord:
   corr_values.iloc[x[0], x[1]] = np.NaN
#Stack a dataframe (return all columns that show for each row and also show tha value)
corr_values = corr_values.stack()
#Change to dataframe
corr_values = corr_values.to_frame()
#Reset the index name, it will show name of columnn are 'level 0', 'level 1', 0
corr_values = corr_values.reset_index()
#Rename the column name
corr_values = corr_values.rename(columns={'level_0':'feature1', 'level_1':'feature2', 0:'correlation'})
corr_values['abs_correlation'] = corr_values.correlation.abs()
#Create a histrogram to see the absolute correlation value
sns.set context('talk')
sns.set_style('white')
ax = corr values.abs correlation.hist(bins=50, figsize=(12, 8))
ax.set(xlabel='Absolute Correlation', ylabel='Frequency')
plt.savefig('histogram.png')
# The most highly correlated values
corr_values.sort_values('correlation', ascending=False).query('abs_correlation>0.8')  # ascending is True mean sort from
### END SOLUTION
```

```
#Split data into train and test data by using StratifiedShuffleSplit
from sklearn.model_selection import StratifiedShuffleSplit
Split = StratifiedShuffleSplit(n_splits=1, test_size=0.3, random_state=42) # n_split = Number of re-shuffling & splitting
Index = Split.split(data2[feature_cols], data2['Activity2']) # .split(X, y) return index of train and test dataset
for Train_index, Test_index in Index:
   X_train = data2.loc[Train_index, feature_cols]
   y_train = data2.loc[Train_index, 'Activity2'] # .loc[name_row, name_col] but .iloc[number_row, number_col]
   X_test = data2.loc[Test_index, feature_cols]
   y_test = data2.loc[Test_index, 'Activity2']
#Fit Logistic Regression
from sklearn.linear_model import LogisticRegression
#To choose a solver, you might want to consider the following aspects:
#1.For small datasets, 'liblinear' is a good choice, whereas 'sag' and 'saga' are faster for large ones;
#2.For multiclass problems, only 'newton-cg', 'sag', 'saga' and 'lbfgs' handle multinomial loss;
#3.'liblinear' and is limited to one-versus-rest schemes.
#4.'newton-cholesky' is a good choice for n_samples >> n_features, especially with one-hot encoded categorical features
# Note that it is limited to binary classification and the one-versus-rest reduction for multiclass classification.
# Be aware that the memory usage of this solver has a quadratic dependency on n features because it explicitly computes the
Hessian matrix.
LR = LogisticRegression(solver= 'liblinear').fit(X_train, y_train) # return equation that fit the X_train and y_train
# Using cross validation to determine the hyperparameters and fit models using L1 and L2 regularization.
from sklearn.linear_model import LogisticRegressionCV
```

LR\_L1 = LogisticRegressionCV(Cs=10, cv=4, penalty='l1', solver='liblinear').fit(X\_train, y\_train)

LR\_L2 = LogisticRegressionCV(Cs=10, cv=4, penalty='l2', solver='liblinear').fit(X\_train, y\_train)

# L1 regularized logistic regression

# L2 regularized logistic regression

#Compare the magnitudes of the coefficients for each of the models. coefficients = list() coeff labels = ['LR', 'L1', 'L2'] coeff\_models = [LR, LR\_L1, LR\_L2] for lab,mod in zip(coeff\_labels, coeff\_models): # from zip lab is in coeff\_labels and mod is is coeff\_models coeffs = mod.coef\_ coeff label = pd.MultiIndex(levels=[[lab], [0,1,2,3,4,5]], codes=[[0,0,0,0,0,0], [0,1,2,3,4,5]]) # levels is index name and codes is ตำแหน่ง พองindex ตบใน coefficients.append(pd.DataFrame(coeffs.T, columns=coeff\_label)) # coeff.T for chanege the shape from (1, n\_features) #coefficients ທີ່ໄດ້ຈະນີ 3 dataframe ເນື່ອงຈາກloop ໂດຍloop1 is LR, loop2 is LR L1 and loop3 is LR L2 coefficients = pd.concat(coefficients, axis=1) # นำข้อมูลของแต่ละ dataframe รวมให้เป็น1 dataframe โดยที่ไม่แยก index กัน ระหว่าง dataframe axis=0 # Visualize the dataframe to see relation fig, axList = plt.subplots(nrows=3, ncols=2) #แสดงกราฟทั้งหมด 6 กราฟ โดยแบ้งเป็น 3 rows 2 columns โดยตำแหน่งจะเก็บใน axList เช่น รูปแถวที่ 1 คอลัมน์ที่ 2 จะได้ว่า axList = axList.flatten() fig.set size inches(10,10) # set ขนาดของ fig โดยจะกำหนดค่าของ ความกว้าง(แกน x) และ ความสูง(แกน y)

```
# Visualize the dataframe to see relation
fig, axList = plt.subplots(nrows=3, ncols=2) #แกลงการที่ก็ควกค 6 การที่โดยเกรี่ม 7 rows 2 columns ໂດຍຄົນພາກີນ axList ເຂ່ນຊຸນີພວກີນ 1 ຄອຄັນນີກີ 2 ຂະໃຫ້
ax.List[0, 1]
axList = axList.flatten() #แก็ดนอก array 2D ເປ็ນ 1D โดยคิดเกานี่สาวถึงการีของนับจากแลวก่อน แล้วใต้ไปลามจำนวนคอดันน์ เช่น รูปแลวที่ 2 คอคัมน์
we ได้ว่า ax.List[3]
fig.set_size_inches(10,10) # set จนาดจอง fig โดยจะกำหนดกำหอง ความกรั้งผดกน x) และ ความสุงผกน y)

# the enumerate() function adds a counter to an iterable. It returns an iterator that produces tuples containing (index, element) for each element in the input iterable.
for ax in enumerate(axList): # ax[0] จะมี 0, 1, 2, 3, 4, 5 ax[1] จะมี 0, 1, 2, 3, 4, 5

loc = ax[0]
ax = ax[1]

# .xs function แสดงกำหาย label สมที่กำหาด axis = 0 หมายถึง row , axis = 1 หมายถึง column data = coefficients.xs(loc, level=1, axis=1)
data.plot(marker='o', ls='', ms=2.0, ax=ax, legend=False)

if ax is axList[0]:
ax.legend(loc=4)
```

ax.set(title='Coefficient Set '+str(loc))

plt.tight\_layout()

```
# Predict the class and the probability for each
y_pred = list()
y_prob = list()
coeff labels = ['lr', 'l1', 'l2']
coeff_models = [lr, lr_l1, lr_l2]
for lab,mod in zip(coeff_labels, coeff_models):
   y_pred.append(pd.Series(mod.predict(X_test), name=lab))
   y_prob.append(pd.Series(mod.predict_proba(X_test).max(axis=1), name=lab))
y_pred = pd.concat(y_pred, axis=1)
y_prob = pd.concat(y_prob, axis=1)
# Calculate error metrics
### BEGIN SOLUTION
from sklearn.metrics import precision_recall_fscore_support as score
from sklearn.metrics import confusion_matrix, accuracy_score, roc_auc_score
from sklearn.preprocessing import label binarize
metrics = list()
cm = dict()
for lab in coeff labels:
   # Preciision, recall, f-score from the multi-class support function
   precision, recall, fscore, _ = score(y_test, y_pred[lab], average='weighted')
   accuracy = accuracy_score(y_test, y_pred[lab])
   # ROC-AUC scores can be calculated by binarizing the data
   auc = roc_auc_score(label_binarize(y_test, classes=[0,1,2,3,4,5]),
             label_binarize(y_pred[lab], classes=[0,1,2,3,4,5]),
```

metrics = pd.concat(metrics, axis=1)

```
### BEGIN SOLUTION
fig, axList = plt.subplots(nrows=2, ncols=2)
axList = axList.flatten()
fig.set_size_inches(12, 10)

axList[-1].axis('off')

for ax,lab in zip(axList[:-1], coeff_labels):
    sns.heatmap(cm[lab], ax=ax, annot=True, fmt='d');
    ax.set(title=lab);

plt.tight_layout()
### END SOLUTION
```